

과제3 -4장

```
#1 일표본 t검정 함수
x <- c(2.7, 2.5, 2.5, 2.6, 2.5, 2.3, 3.3, 1.8, 2.7, 2.9, NA,
      2.9, 3.1, 2.4, 2.9, 3.2, 2.5, 3.2, 2.8, 2.6, 2.9, NA,
      1.8, 3.1, 2.6, 2.5, 2.7, 3.1, 2.7, 3.1, 2.7, 3.0, NA,
      2.3, 2.9, 2.5, 3.3, 2.0, 2.2, 2.9, 3.1, 3.2, 2.0, NA)
x <- na.omit(x)
mn =mean(x)
sigma = 0.397
alpha = 0.05
zstat=(mn-2.5)/(sigma/sqrt(40))
pval <- 1-pnorm(zstat)
mu0 <-0
```

```
listresult = list(mn =mean(x),sd = sd(x),
                  zstat=(mn-2.5)/(sigma/sqrt(40)),decision = if(pval < c(alpha)){
    print("Reject H0")
  }else {
    print("Do Not reject H0")},ci =c(mn-(1.96 %*% (sigma/sqrt(40))),mn+(1.96 %*% (sigma/sqrt(40
))))),sigma = 0.397,alpha = 0.05)
```

```
## [1] "Reject H0"
```

```
listresult
```

```
## $mn
## [1] 2.7
##
## $sd
## [1] 0.3967819
##
## $zstat
## [1] 3.186174
##
## $decision
## [1] "Reject H0"
##
## $ci
## [1] 2.576968 2.823032
##
## $sigma
## [1] 0.397
##
## $alpha
## [1] 0.05
```

```
#tips.csv처리
library(tidyverse)
```

```
## -- Attaching packages ----- tidyverse 1.3.1 --
```

```
## v ggplot2 3.3.5      v purrr   0.3.4
## v tibble  3.1.4      v dplyr   1.0.7
## v tidyr   1.1.4      v stringr 1.4.0
## v readr   2.0.2      v forcats 0.5.1
```

```
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()
```

```
TIPS <- read.csv("C:\\Users\\WWUser\\Desktop\\data\\tips.csv")
TIPS$sex= factor(TIPS$sex)
TIPS$smoker= factor(TIPS$smoker)
TIPS$day= factor(TIPS$day)
TIPS$time= factor(TIPS$time)
TIPS$tiprate = TIPS$tip /TIPS$total_bill
write.csv(TIPS, file="TIPS.csv")
```

#3.4장 코드 실행

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students1.txt",header=T) # 파일 마지막 행에서 [Enter]를 누르지 않은 경우
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students2.txt",header=T) #파일 마지막 행에서 [Enter]를 누른 경우
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int   100  90  90  100  85
## $ english: int   90  100  95  85  100
## $ math   : int   100  80  90  95  100
```

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students1.txt",header=T,as.is=TRUE)
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int   100  90  90  100  85
## $ english: int   90  100  95  85  100
## $ math   : int   100  80  90  95  100
```

파일을 있는 형태 그대로 읽음. as.is=TRUE 면 문자를 문자로 읽음

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, stringsAsFactors =FALSE)
str(df)
```

```
## 'data.frame':   5 obs. of  4 variables:
## $ name.   : chr  "강서준," "김도형," "박정원," "이상훈," ...
## $ korean. : chr  "100," "90," "90," "100," ...
## $ english.: chr  "90," "100," "95," "85," ...
## $ math    : int  100 80 90 NA 100
```

파일을 읽을 때 문장을 요인으로 인식하지 않도록 설정.

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, sep=',',
stringsAsFactors =FALSE)
str(df)
```

```
## 'data.frame':   5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int  100 90 90 100 85
## $ english: int  90 100 95 85 100
## $ math   : chr  " 100" " 80" " 90" " NA" ...
```

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, sep=',',
as.is=TRUE)
str(df)
```

```
## 'data.frame':   5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int  100 90 90 100 85
## $ english: int  90 100 95 85 100
## $ math   : chr  " 100" " 80" " 90" " NA" ...
```

구분 기호는 쉼표(,), 첫 행은 header로 인식하여 파일을 있는 그대로 읽어들이면
NA로 인해 math 요소가 문장으로 인식됨

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, sep=',',
as.is=TRUE, na.strings= 'NA')
str(df)
```

```
## 'data.frame':   5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int  100 90 90 100 85
## $ english: int  90 100 95 85 100
## $ math   : chr  " 100" " 80" " 90" " NA" ...
```

'NA' 문장을 결측값 NA로 처리하라고 해도 처리가 안됨. 정확한 문장은 NA 앞에 빈 칸이 있어야 하기 때문

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, sep=',',
as.is=TRUE, na.strings= ' NA')
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name      : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean    : int   100  90  90  100  85
## $ english   : int   90  100  95  85  100
## $ math      : int   100  80  90 NA  100
```

'NA'로 정확하게 입력하자 결측값 NA로 처리되면서 math 요소가 모두 숫자로 인식됨

```
df <- read.table("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students3.txt",header=TRUE, sep=',',
as.is=TRUE,strip.white=TRUE)
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name      : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean    : int   100  90  90  100  85
## $ english   : int   90  100  95  85  100
## $ math      : int   100  80  90 NA  100
```

strip.white에서 빈칸을 제거하면 na.string의 기본값이 'NA'로 설정되어 math 요소가 모두 숫자로 인식됨.

```
# 첫 행이 header이므로 header 옵션을 지정할 필요가 없음
df <- read.csv("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students.csv")
df
```

```
##      name korean english math
## 1 강서준    100      90    100
## 2 김도형     90    100     80
## 3 박정원     90     95     90
## 4 이상훈    100     85     95
## 5 최건우     85    100    100
```

```
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name      : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean    : int   100  90  90  100  85
## $ english   : int   90  100  95  85  100
## $ math      : int   100  80  90  95  100
```

```
df$name <- as.character(df$name)
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name      : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean    : int   100  90  90  100  85
## $ english   : int   90  100  95  85  100
## $ math      : int   100  80  90  95  100
```

```
df <- read.csv("C:\\Users\\User\\Desktop\\data\\Sources\\students.csv", stringsAsFactors = FALSE)
str(df)
```

```
## 'data.frame':    5 obs. of  4 variables:
## $ name   : chr  "강서준" "김도형" "박정원" "이상훈" ...
## $ korean : int   100  90  90  100  85
## $ english: int   90  100  95  85  100
## $ math   : int   100  80  90  95  100
```

```
# 파일을 읽을 때 문장을 요인으로 인식하지 않도록 설정함
```

```
df <- read.table("C:\\Users\\User\\Desktop\\data\\Sources\\students3.txt", header=TRUE, sep=',',
as.is=TRUE)
```

```
write.table(df, file="C:\\Users\\User\\Desktop\\data\\Sources\\output.txt")
# 문장에 큰따옴표가 표시됨.
```

```
test <- c(15, 20, 30, NA, 45)
test[test<40]
```

```
## [1] 15 20 30 NA
```

```
test[test%%3!= 0]
```

```
## [1] 20 NA
```

```
test[is.na(test)]
```

```
## [1] NA
```

```
test[!is.na(test)]
```

```
## [1] 15 20 30 45
```

```
test[test%%2==0 & !is.na(test)]
```

```
## [1] 20 30
```

```
DF <- data.frame(
  name = c('길동', '춘향', '철수'),
  age = c(30, 16, 21),
  gender = factor(c('M', 'F', 'M'))) # 데이터 프레임인 경우
DF
```

```
##   name age gender
## 1 길동  30      M
## 2 춘향  16      F
## 3 철수  21      M
```

```
DF[DF$gender=='F', ] # 성별이 여성인 행 추출
```

```
##   name age gender
## 2 춘향  16      F
```

```
DF[DF$age<30 & DF$gender=='M', ] # 30살 미만의 남성 행 추출
```

```
##   name age gender
## 3 철수  21      M
```

```
x <- 5
if(x%%2 == 0) {
  print('x는 짝수') # 조건식이 참
} else {
  print('x는 홀수') # 조건식이 거짓
}
```

```
## [1] "x는 홀수"
```

```
x <- -1
if(x>0) {
  print('x is a positive value.') # x가 0보다 크면 출력
} else if(x<0) {
  print('x is a negative value.') # 위 조건을 만족하지 않고 x가 0보다 작으면 출력
} else {
  print('x is zero.') # 위 조건을 모두 만족하지 않으면 출력
}
```

```
## [1] "x is a negative value."
```

```
x <- c(-5:5)
options(digits=3)
sqrt(x)
```

```
## Warning in sqrt(x): NaN이 생성되었습니다
```

```
## [1] NaN NaN NaN NaN NaN 0.00 1.00 1.41 1.73 2.00 2.24
```

```
sqrt(ifelse(x>=0, x, NA)) # NaN이 발생하지 않게 음수면 NA로 표시
```

```
## [1] NA NA NA NA NA 0.00 1.00 1.41 1.73 2.00 2.24
```

```
DF <- read.csv("C:\\Users\\WWUser\\Desktop\\data\\Sources\\students.csv")
DF
```

```
##      name korean english math
## 1 강서준    100      90    100
## 2 김도형     90     100     80
## 3 박정원     90     95     90
## 4 이상훈    100     85     95
## 5 최건우     85     100    100
```

```
DF[, 2] = ifelse(DF[, 2]>= 0 & DF[, 2]<= 100, DF[, 2], NA)
DF[, 3] = ifelse(DF[, 3]>= 0 & DF[, 3]<= 100, DF[, 3], NA)
DF[, 4] = ifelse(DF[, 4]>= 0 & DF[, 4]<= 100, DF[, 4], NA)
DF # ifelse 문으로 2~4열 값 중 0~100 외의 값은 NA로 처리함
```

```
##      name korean english math
## 1 강서준    100      90    100
## 2 김도형     90     100     80
## 3 박정원     90     95     90
## 4 이상훈    100     85     95
## 5 최건우     85     100    100
```

```
# repeat 문을 이용해 1부터 10까지 숫자 증가시키기
i <- 1 # i의 시작값은 1
repeat {
  if(i>10) { # i가 10을 넘으면 반복을 중단(break)함
    break
  } else {
    print(i)
    i <- i+1 # i를 1 증가시킴.
  }
}
```

```
## [1] 1
## [1] 2
## [1] 3
## [1] 4
## [1] 5
## [1] 6
## [1] 7
## [1] 8
## [1] 9
## [1] 10
```

```
# while 문을 이용해 1부터 10까지 숫자 증가시키기
i <- 1 # i의 시작값은 1임.
while(i <= 10){ # i가 10 이하인 동안에 반복함
  print(i)
  i <- i+1 } #i를 1증가시킴.
```

```
## [1] 1
## [1] 2
## [1] 3
## [1] 4
## [1] 5
## [1] 6
## [1] 7
## [1] 8
## [1] 9
## [1] 10
```

```
# while 문을 이용해 구구단 2단 만들기
i <- 1
while(i<10) {
  print(paste(2, 'X', i, '=', 2*i))
  i <- i+1
}
```

```
## [1] "2 X 1 = 2"
## [1] "2 X 2 = 4"
## [1] "2 X 3 = 6"
## [1] "2 X 4 = 8"
## [1] "2 X 5 = 10"
## [1] "2 X 6 = 12"
## [1] "2 X 7 = 14"
## [1] "2 X 8 = 16"
## [1] "2 X 9 = 18"
```

```
# for 문을 이용한 1부터 10까지 숫자 증가시키기
for(i in 1:10) {
  print(i)
}
```

```
## [1] 1
## [1] 2
## [1] 3
## [1] 4
## [1] 5
## [1] 6
## [1] 7
## [1] 8
## [1] 9
## [1] 10
```

```
# for 문을 이용해 구구단 2단 만들기
for(i in 1:9) {
  print(paste(2, 'X', i, '=', 2*i))
}
```



```
## [1] "2 X 1 = 2"  
## [1] "2 X 2 = 4"  
## [1] "2 X 3 = 6"  
## [1] "2 X 4 = 8"  
## [1] "2 X 5 = 10"  
## [1] "2 X 6 = 12"  
## [1] "2 X 7 = 14"  
## [1] "2 X 8 = 16"  
## [1] "2 X 9 = 18"
```

```
# for 문을 이용해 구구단 2~9단 만들기  
for(i in 2:9) {  
  for(j in 1:9) {  
    print(paste(i, 'X', j, '=', i*j))  
  }  
}
```

[1] "2 X 1 = 2"
[1] "2 X 2 = 4"
[1] "2 X 3 = 6"
[1] "2 X 4 = 8"
[1] "2 X 5 = 10"
[1] "2 X 6 = 12"
[1] "2 X 7 = 14"
[1] "2 X 8 = 16"
[1] "2 X 9 = 18"
[1] "3 X 1 = 3"
[1] "3 X 2 = 6"
[1] "3 X 3 = 9"
[1] "3 X 4 = 12"
[1] "3 X 5 = 15"
[1] "3 X 6 = 18"
[1] "3 X 7 = 21"
[1] "3 X 8 = 24"
[1] "3 X 9 = 27"
[1] "4 X 1 = 4"
[1] "4 X 2 = 8"
[1] "4 X 3 = 12"
[1] "4 X 4 = 16"
[1] "4 X 5 = 20"
[1] "4 X 6 = 24"
[1] "4 X 7 = 28"
[1] "4 X 8 = 32"
[1] "4 X 9 = 36"
[1] "5 X 1 = 5"
[1] "5 X 2 = 10"
[1] "5 X 3 = 15"
[1] "5 X 4 = 20"
[1] "5 X 5 = 25"
[1] "5 X 6 = 30"
[1] "5 X 7 = 35"
[1] "5 X 8 = 40"
[1] "5 X 9 = 45"
[1] "6 X 1 = 6"
[1] "6 X 2 = 12"
[1] "6 X 3 = 18"
[1] "6 X 4 = 24"
[1] "6 X 5 = 30"
[1] "6 X 6 = 36"
[1] "6 X 7 = 42"
[1] "6 X 8 = 48"
[1] "6 X 9 = 54"
[1] "7 X 1 = 7"
[1] "7 X 2 = 14"
[1] "7 X 3 = 21"
[1] "7 X 4 = 28"
[1] "7 X 5 = 35"
[1] "7 X 6 = 42"
[1] "7 X 7 = 49"
[1] "7 X 8 = 56"
[1] "7 X 9 = 63"
[1] "8 X 1 = 8"

```
## [1] "8 X 2 = 16"
## [1] "8 X 3 = 24"
## [1] "8 X 4 = 32"
## [1] "8 X 5 = 40"
## [1] "8 X 6 = 48"
## [1] "8 X 7 = 56"
## [1] "8 X 8 = 64"
## [1] "8 X 9 = 72"
## [1] "9 X 1 = 9"
## [1] "9 X 2 = 18"
## [1] "9 X 3 = 27"
## [1] "9 X 4 = 36"
## [1] "9 X 5 = 45"
## [1] "9 X 6 = 54"
## [1] "9 X 7 = 63"
## [1] "9 X 8 = 72"
## [1] "9 X 9 = 81"
```

```
# 1부터 10까지의 수 중 짝수만 출력하기
for(i in 1:10) {
  if(i%%2 == 0) {
    print(i)}}

```

```
## [1] 2
## [1] 4
## [1] 6
## [1] 8
## [1] 10
```

```
# 1부터 10까지의 수 중 소수 출력하기
for(i in 1:10){
  check=0
  for (j in 1:i){
    if(i%%j ==0){
      check = check+1
    }
  }
  if(check==2){
    print(i)
  }
}
```

```
## [1] 2
## [1] 3
## [1] 5
## [1] 7
```

```
df <- read.csv("C:\\Users\\WWUser\\Desktop\\WWdata\\WWSources\\WWstudents.csv")
df # 데이터에 100 초과 값과 음수 값이 포함되어 있음
```

```
##      name korean english math
## 1 강서준    100     90   100
## 2 김도형     90    100    80
## 3 박정원     90     95    90
## 4 이상훈    100     85    95
## 5 최건우     85    100   100
```

```
for(i in 2:4){
  df[,i] <- ifelse(df[,i]>=0 & df[,i]<=100,df[,i],NA)
}
df
```

```
##      name korean english math
## 1 강서준    100     90   100
## 2 김도형     90    100    80
## 3 박정원     90     95    90
## 4 이상훈    100     85    95
## 5 최건우     85    100   100
```

```
fact <- function(x) { # 함수의 이름은 fact, 입력은 x
  fa <- 1 # 계승값을 저장할 변수
  while(x>1) { # x가 1보다 큰 동안 반복
    fa <- fa*x # x 값을 fa에 곱한 후 fa에 다시 저장
    x <- x-1 # x 값을 1 감소
  }
  return(fa) # 최종 계산된 fa 반환
}
fact(5) # 5!을 계산한 결과 출력
```

```
## [1] 120
```

```
my.is.na<-function(x) {
  table(is.na(x))
}
```

```
my.is.na(airquality) # 이 결과는 table(is.na(airquality))와 같음.
```

```
##
## FALSE  TRUE
##   874    44
```

```
table(is.na(airquality))
```

```
##
## FALSE  TRUE
##   874    44
```

```
str(airquality) # airquality 데이터의 구조를 살펴봄.
```

```
## 'data.frame': 153 obs. of 6 variables:
## $ Ozone : int 41 36 12 18 NA 28 23 19 8 NA ...
## $ Solar.R: int 190 118 149 313 NA NA 299 99 19 194 ...
## $ Wind : num 7.4 8 12.6 11.5 14.3 14.9 8.6 13.8 20.1 8.6 ...
## $ Temp : int 67 72 74 62 56 66 65 59 61 69 ...
## $ Month : int 5 5 5 5 5 5 5 5 5 5 ...
## $ Day : int 1 2 3 4 5 6 7 8 9 10 ...
```

airquality 데이터에서 NA인 것은 TRUE, 아니면 FALSE로 나타냄. 데이터가 많아 head 함수로 추려냄.

```
head(is.na(airquality))
```

```
##      Ozone Solar.R Wind Temp Month Day
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE FALSE FALSE FALSE
## [3,] FALSE FALSE FALSE FALSE FALSE FALSE
## [4,] FALSE FALSE FALSE FALSE FALSE FALSE
## [5,] TRUE TRUE FALSE FALSE FALSE FALSE
## [6,] FALSE TRUE FALSE FALSE FALSE FALSE
```

```
table(is.na(airquality)) # NA가 총 44개 있음.
```

```
##
## FALSE TRUE
## 874 44
```

```
table(is.na(airquality$Temp)) # Temp에는 NA가 없음을 확인함.
```

```
##
## FALSE
## 153
```

```
table(is.na(airquality$Ozone)) # Ozone에는 NA가 37개 발견됨.
```

```
##
## FALSE TRUE
## 116 37
```

```
mean(airquality$Temp) # NA가 없는 Temp는 평균이 구해짐.
```

```
## [1] 77.9
```

```
mean(airquality$Ozone) # NA가 있는 Ozone은 평균이 NA로 나옴.
```

```
## [1] NA
```

```
air_narm = airquality[!is.na(airquality$ozone), ] # ozone 속성에서 NA가 없는 값만 추출함.  
air_narm
```

##	Ozone	Solar.R	Wind	Temp	Month	Day
## 1	41	190	7.4	67	5	1
## 2	36	118	8.0	72	5	2
## 3	12	149	12.6	74	5	3
## 4	18	313	11.5	62	5	4
## 6	28	NA	14.9	66	5	6
## 7	23	299	8.6	65	5	7
## 8	19	99	13.8	59	5	8
## 9	8	19	20.1	61	5	9
## 11	7	NA	6.9	74	5	11
## 12	16	256	9.7	69	5	12
## 13	11	290	9.2	66	5	13
## 14	14	274	10.9	68	5	14
## 15	18	65	13.2	58	5	15
## 16	14	334	11.5	64	5	16
## 17	34	307	12.0	66	5	17
## 18	6	78	18.4	57	5	18
## 19	30	322	11.5	68	5	19
## 20	11	44	9.7	62	5	20
## 21	1	8	9.7	59	5	21
## 22	11	320	16.6	73	5	22
## 23	4	25	9.7	61	5	23
## 24	32	92	12.0	61	5	24
## 28	23	13	12.0	67	5	28
## 29	45	252	14.9	81	5	29
## 30	115	223	5.7	79	5	30
## 31	37	279	7.4	76	5	31
## 38	29	127	9.7	82	6	7
## 40	71	291	13.8	90	6	9
## 41	39	323	11.5	87	6	10
## 44	23	148	8.0	82	6	13
## 47	21	191	14.9	77	6	16
## 48	37	284	20.7	72	6	17
## 49	20	37	9.2	65	6	18
## 50	12	120	11.5	73	6	19
## 51	13	137	10.3	76	6	20
## 62	135	269	4.1	84	7	1
## 63	49	248	9.2	85	7	2
## 64	32	236	9.2	81	7	3
## 66	64	175	4.6	83	7	5
## 67	40	314	10.9	83	7	6
## 68	77	276	5.1	88	7	7
## 69	97	267	6.3	92	7	8
## 70	97	272	5.7	92	7	9
## 71	85	175	7.4	89	7	10
## 73	10	264	14.3	73	7	12
## 74	27	175	14.9	81	7	13
## 76	7	48	14.3	80	7	15
## 77	48	260	6.9	81	7	16
## 78	35	274	10.3	82	7	17
## 79	61	285	6.3	84	7	18
## 80	79	187	5.1	87	7	19
## 81	63	220	11.5	85	7	20
## 82	16	7	6.9	74	7	21
## 85	80	294	8.6	86	7	24

## 86	108	223	8.0	85	7	25
## 87	20	81	8.6	82	7	26
## 88	52	82	12.0	86	7	27
## 89	82	213	7.4	88	7	28
## 90	50	275	7.4	86	7	29
## 91	64	253	7.4	83	7	30
## 92	59	254	9.2	81	7	31
## 93	39	83	6.9	81	8	1
## 94	9	24	13.8	81	8	2
## 95	16	77	7.4	82	8	3
## 96	78	NA	6.9	86	8	4
## 97	35	NA	7.4	85	8	5
## 98	66	NA	4.6	87	8	6
## 99	122	255	4.0	89	8	7
## 100	89	229	10.3	90	8	8
## 101	110	207	8.0	90	8	9
## 104	44	192	11.5	86	8	12
## 105	28	273	11.5	82	8	13
## 106	65	157	9.7	80	8	14
## 108	22	71	10.3	77	8	16
## 109	59	51	6.3	79	8	17
## 110	23	115	7.4	76	8	18
## 111	31	244	10.9	78	8	19
## 112	44	190	10.3	78	8	20
## 113	21	259	15.5	77	8	21
## 114	9	36	14.3	72	8	22
## 116	45	212	9.7	79	8	24
## 117	168	238	3.4	81	8	25
## 118	73	215	8.0	86	8	26
## 120	76	203	9.7	97	8	28
## 121	118	225	2.3	94	8	29
## 122	84	237	6.3	96	8	30
## 123	85	188	6.3	94	8	31
## 124	96	167	6.9	91	9	1
## 125	78	197	5.1	92	9	2
## 126	73	183	2.8	93	9	3
## 127	91	189	4.6	93	9	4
## 128	47	95	7.4	87	9	5
## 129	32	92	15.5	84	9	6
## 130	20	252	10.9	80	9	7
## 131	23	220	10.3	78	9	8
## 132	21	230	10.9	75	9	9
## 133	24	259	9.7	73	9	10
## 134	44	236	14.9	81	9	11
## 135	21	259	15.5	76	9	12
## 136	28	238	6.3	77	9	13
## 137	9	24	10.9	71	9	14
## 138	13	112	11.5	71	9	15
## 139	46	237	6.9	78	9	16
## 140	18	224	13.8	67	9	17
## 141	13	27	10.3	76	9	18
## 142	24	238	10.3	68	9	19
## 143	16	201	8.0	82	9	20
## 144	13	238	12.6	64	9	21
## 145	23	14	9.2	71	9	22
## 146	36	139	10.3	81	9	23


```
## 147      7      49 10.3   69      9  24
## 148     14      20 16.6   63      9  25
## 149     30     193  6.9   70      9  26
## 151     14     191 14.3   75      9  28
## 152     18     131  8.0   76      9  29
## 153     20     223 11.5   68      9  30
```

```
mean(air_narm$Ozone) # 결측값이 제거된 데이터에서는 mean 함수가 정상적으로 동작함.
```

```
## [1] 42.1
```

```
# na.omit 함수를 이용해 결측값 처리하기
air_narm1 = na.omit(airquality)
mean(air_narm1$Ozone)
```

```
## [1] 42.1
```

```
# 함수 속성인 na.rm을 이용해 결측값 처리하기
mean(airquality$Ozone, na.rm = T)
```

```
## [1] 42.1
```

```
table(is.na(airquality))
```

```
##
## FALSE  TRUE
##   874    44
```

```
table(is.na(airquality$Ozone))
```

```
##
## FALSE  TRUE
##   116    37
```

```
table(is.na(airquality$Solar.R))
```

```
##
## FALSE  TRUE
##   146     7
```

```
air_narm = airquality[!is.na(airquality$Ozone) & !is.na(airquality$Solar.R), ]
mean(air_narm$Ozone)
```

```
## [1] 42.1
```

```
patients = data.frame(name = c('환자1', '환자2', '환자3', '환자4', '환자5'), age = c(22, 20, 25, 30, 27), gender=factor(c('M', 'F', 'M', 'K', 'F')), blood.type = factor(c('A', 'O', 'B', 'AB', 'C')))
```

patients

```
##      name age gender blood.type
## 1 환자1  22      M          A
## 2 환자2  20      F          O
## 3 환자3  25      M          B
## 4 환자4  30      K         AB
## 5 환자5  27      F          C
```

```
# 성별에서 이상값 제거
patients_outrm = patients[patients$gender=='M'|patients$gender=='F', ]
patients_outrm
```

```
##      name age gender blood.type
## 1 환자1  22      M          A
## 2 환자2  20      F          O
## 3 환자3  25      M          B
## 5 환자5  27      F          C
```

```
# 성별과 혈액형에서 이상값 제거
patients_outrm1 = patients[(patients$gender == 'M'|patients$gender == 'F') & (patients$blood.type == 'A'|patients$blood.type == 'B'|patients$blood.type == 'O'|patients$blood.type == 'AB'), ]
patients_outrm1
```

```
##      name age gender blood.type
## 1 환자1  22      M          A
## 2 환자2  20      F          O
## 3 환자3  25      M          B
```

```
# 이상값이 포함된 환자 데이터
patients = data.frame(name = c('환자1', '환자2', '환자3', '환자4', '환자5'), age = c(22, 20, 25, 30, 27), gender = c(1, 2, 1, 3, 2), blood.type = c(1, 3, 2, 4, 5))
patients
```

```
##      name age gender blood.type
## 1 환자1  22      1          1
## 2 환자2  20      2          3
## 3 환자3  25      1          2
## 4 환자4  30      3          4
## 5 환자5  27      2          5
```

```
# 성별에 있는 이상값을 결측값으로 변경
patients$gender = ifelse((patients$gender<1|patients$gender>2), NA, patients$gender)
patients
```

```
##      name age gender blood.type
## 1 환자1  22      1         1
## 2 환자2  20      2         3
## 3 환자3  25      1         2
## 4 환자4  30     NA         4
## 5 환자5  27      2         5
```


```
# 혈액형에 있는 이상값도 결측값으로 변경
patients$blood.type = ifelse((patients$blood.type<1|patients$blood.type>4), NA, patients$blood.type)
patients
```

```
##      name age gender blood.type
## 1 환자1  22      1         1
## 2 환자2  20      2         3
## 3 환자3  25      1         2
## 4 환자4  30     NA         4
## 5 환자5  27      2        NA
```


```
# 결측값을 모두 제거
patients[!is.na(patients$gender)&!is.na(patients$blood.type), ]
```

```
##      name age gender blood.type
## 1 환자1  22      1         1
## 2 환자2  20      2         3
## 3 환자3  25      1         2
```

```
boxplot(airquality[, c(1:4)]) # Ozone, Solar.R, Wind, Temp에 대한 boxplot
```



```
boxplot(airquality[, 1])$stats # Ozone의 boxplot 통계값 계산
```



```
##      [,1]
## [1,]  1.0
## [2,] 18.0
## [3,] 31.5
## [4,] 63.5
## [5,]122.0
```

```
air = airquality # 임시 저장 변수로 airquality 데이터 복사
table(is.na(air$Ozone)) # Ozone의 현재 NA 개수 확인
```

```
##
## FALSE  TRUE
##   116    37
```

```
# 이상값을 NA로 변경
air$Ozone = ifelse(air$Ozone<1|air$Ozone>122, NA, air$Ozone)
table(is.na(air$Ozone)) # 이상값 처리 후 NA 개수 확인(2개 증가)
```

```
##
## FALSE  TRUE
##   114    39
```

```
# NA 제거
air_narm = air[!is.na(air$Ozone), ]
mean(air_narm$Ozone) # 이상값 두 개 제거로 is.na 함수를 이용한 결과보다 값이 줄어듦
```

```
## [1] 40.2
```